人工智能基础研究

代表性工作报告

周志明

2026 年 10 月

六项代表性工作

方向	工作
生成模型	LGANs
优化算法	AdaShift
泛化	XSAM
神经网络架构	ResFlow
表示学习	CRED
计算机图形学	Sparse SVBRDF

生成模型：LGANs

第一项工作

LGANs

ICML 2019

唯一一作、共同通讯

最具代表性工作

生成对抗网络

生成模型的目标： $p_g = p_d$，即生成数据分布等于真实数据分布。

经典 GANs 目标函数

$$\min_G \max_D \ \mathbb{E}_{x\sim p_d} \log D(x) + \mathbb{E}_{z\sim p_z} \log\big(1 - D(G(z))\big)$$

当判别器取最优解时，等价于 $\min_G \mathrm{JS}(p_g, p_d)$。

WGANs 目标函数

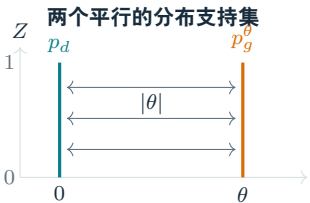
$$\min_G \sup_{\mathrm{Lip}(f)\le 1} [\mathbb{E}_{x\sim p_d} f(x) - \mathbb{E}_{z\sim p_z} f(G(z))]$$

当判别器取最优解时，等价于 $\min_G W_1(p_d, p_g)$。

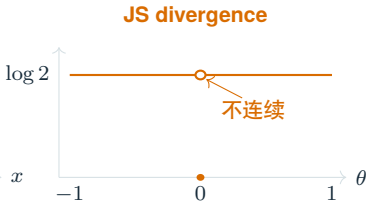
训练不稳定问题⇒ 距离度量

- GANs 容易训崩、出现模式崩塌，即生成分布仅覆盖真实数据的一部分。
- WGANs（该领域最重要的论文之一）指出问题出在距离度量函数上：JS divergence 不连续，Wasserstein-1 distance 连续。

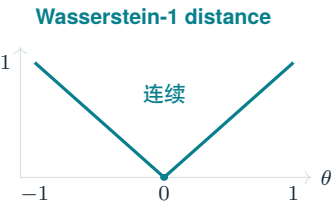
$$Z \sim U[0,1], \qquad p_d = \mathrm{Law}((0,Z)), \qquad p_g^\theta = \mathrm{Law}((\theta,Z))$$



$\theta \neq 0$：两分布支持集不相交



$\mathrm{JS} = \log 2\ (\theta \neq 0)$；$\mathrm{JS} = 0\ (\theta = 0)$



$W_1(p_d, p_g^\theta) = |\theta|$

$\theta \to 0$ 时，支持集逐渐接近；JS 在零点跳变，W_1 连续趋于零。

训练不稳定能否简单归因于距离度量的不连续性？

揭示 GANs 训练不稳定更底层的机制：

- 根源不在于距离度量函数的连续性，而在于判别器给生成器的梯度是否能有效传递信息。
- 即使采用连续性良好的 W_1 distance，在等价目标函数中放松 Lipschitz 约束，理论上依然可能得到缺乏有效信息的梯度。
- Wasserstein distance 的核心是其中的 Lipschitz 约束；它是能使判别器向生成器传递可靠信息的一般性约束。
- 提出以 Lipschitz 约束为核心的一般框架 LGANs。证明在最优判别函数下，梯度有信息，并直接从当前生成样本指向一个真实样本。

更多内容

- 如果 GANs 的判别器不加任何约束，不论如何改写目标函数，其最优判别函数仍会出现缺乏有效信息的情况。
- 解释模式崩塌现象是如何出现的。
- 提出 MaxGP，改进 Lipschitz 约束的实现。经典 Gradient Penalty 存在问题，这是 WGANs 仍不够稳定的原因之一。

提出的方法

LGANs

$$\begin{aligned}\min_{f\in\mathcal{F}} \quad & \mathbb{E}_{x\sim P_r}[\varphi(f(x))] + \mathbb{E}_{z\sim P_z}[\phi(f(g(z)))] \\ & + \lambda k(f)^2, \\ \min_{g\in\mathcal{G}} \quad & \mathbb{E}_{z\sim P_z}[\psi(f(g(z)))].\end{aligned}$$

其中，$k(f)$ **为 Lipschitz 常数**：

$$k(f) = \sup_{x\neq y} \frac{|f(x)-f(y)|}{\|x-y\|_2}.$$

要求：

$$\begin{cases}\varphi''(x) \geq 0, \quad \phi''(x) \geq 0, & \forall x \in \mathbb{R}, \\ \exists a \in \mathbb{R}, \quad \varphi'(a) + \phi'(a) = 0.\end{cases}$$

GP

$$\mathcal{L}_{\mathrm{GP}} = \lambda \mathbb{E}_{\hat{x}\sim P_{\hat{x}}}\left[(\|\nabla_{\hat{x}} f(\hat{x})\|_2 - 1)^2\right].$$

MaxGP

$$\mathcal{L}_{\mathrm{MaxGP}} = \lambda \max_{\hat{x}\sim P_{\hat{x}}} \|\nabla_{\hat{x}} f(\hat{x})\|_2^2.$$

实验结果

训练更稳定

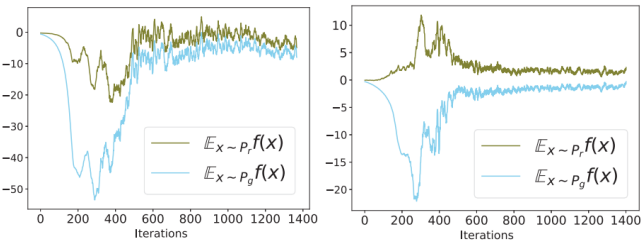


Figure 5: $f^*(x)$ in LGANs is more stable. Left: WGAN. Right: LGANs.

生成质量更高

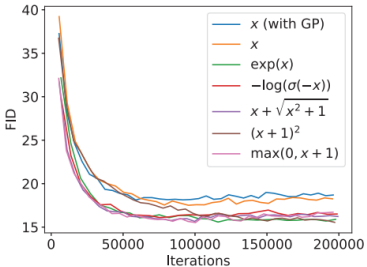


Figure 4: Training curves on CIFAR.

GANs 真的不稳定吗？

作者研究观点

LGANs + MaxGP 能在真实图片数据集上，稳定学到最优解：

$$\boxed{p_g = p_d}$$

前提：网络结构合理且足够大、训练足够久。

优化算法：AdaShift

第二项工作

AdaShift

ICLR 2019

共同一作

另一个同期工作

Adam

目前依旧是主流优化器之一，另一个是 Muon。

设 $g_t = \nabla_\theta \mathcal{L}(\theta_{t-1})$。

一阶矩（Momentum） $m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t,$

二阶原始矩 $v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2,$

偏差修正 $\hat{m}_t = \dfrac{m_t}{1-\beta_1^t}, \qquad \hat{v}_t = \dfrac{v_t}{1-\beta_2^t},$

参数更新 $\theta_t = \theta_{t-1} - \eta_t \dfrac{\hat{m}_t}{\sqrt{\hat{v}_t} + \epsilon}.$

核心：通过二阶矩估计 v 做梯度归一化

使优化器对梯度的实际 scale 不敏感。

Adam 的不收敛问题

AMSGrad（ICLR 2018，best paper）

- Adam 可能导致训练不收敛。
- 从数学证明角度，收敛性证明假设有效学习率单调变化，实际却可能非单调。

提出的解决方案

$$
\begin{aligned}
g_t &= \nabla_\theta \mathcal{L}(\theta_{t-1}), \\
m_t &= \beta_{1,t} m_{t-1} + (1-\beta_{1,t}) g_t, \\
v_t &= \beta_2 v_{t-1} + (1-\beta_2) g_t^2, \\
\hat{v}_t &= \max(\hat{v}_{t-1}, v_t), \\
\theta_t &= \theta_{t-1} - \eta_t \frac{m_t}{\sqrt{\hat{v}_t} + \epsilon}.
\end{aligned}
$$

对 v 取最大值，强制单调。

作者评价：治标不治本

$$
\begin{aligned}
g_t &= \nabla_\theta \mathcal{L}(\theta_{t-1}), \\
m_t &= \beta_{1,t} m_{t-1} + (1-\beta_{1,t}) g_t, \\
v_t &= \beta_{2,t} v_{t-1} + (1-\beta_{2,t}) g_t^2, \\
\theta_t &= \theta_{t-1} - \eta_t \frac{m_t}{\sqrt{v_t} + \epsilon}.
\end{aligned}
$$

要求 β_2 后期趋于 1，使 v 在训练后期趋于常数。

不收敛能否简单归因于有效学习率可能出现非单调变化？

有更底层的原因：v_t 和 g_t 存在相关性。

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2$$

- g_t 越大，v_t 越大；g_t 越小，v_t 越小。
- 用 v_t 归一化后：
  - 大 g_t 的有效更新步长相对更小；
  - 小 g_t 的有效更新步长相对更大。
- 从而可能存在反例：g_t 的累积更新方向发生偏移，甚至完全相反。

提出的方法

底层原因： v_t 和 g_t 存在相关性。

解决方案： 通过时序偏移去除相关性。

核心机制

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_{t-n}^2$$

使 v_t 不用到 g_t，只用前面的梯度估计二阶矩。

完整算法

$$g_t = \nabla_\theta \mathcal{L}(\theta_{t-1}),$$

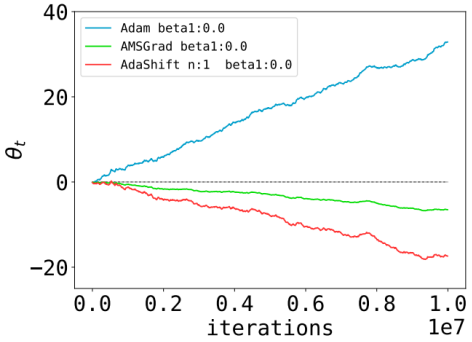
$$m_t = \frac{\sum_{i=0}^{n-1} \beta_1^i g_{t-i}}{\sum_{i=0}^{n-1} \beta_1^i},$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2)\phi(g_{t-n}^2),$$

$$\theta_t = \theta_{t-1} - \eta_t \frac{m_t}{\sqrt{v_t} + \epsilon}.$$

实验结果

AdaShift 比 AMSGrad **收敛更快**



AdaShift 比 AMSGrad **收敛更好**

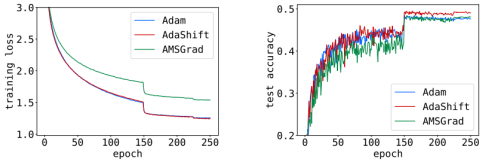
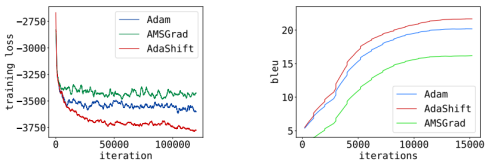


Figure 6: DenseNet on Tiny-ImageNet.



(a) Training WGAN Discriminator. (b) Neural Machine Translation BLEU.

Figure 7: Generative and Recurrent model.

Adam 不收敛真的是个问题吗？

作者研究观点

是也不是。对绝大多数真实场景训练几乎没有影响。

但其步长稳定性和归一化的优点一直存在，Muon 的核心优点也类似。

Muon 也有类似问题，即每个梯度的累积更新步长不一致，但也许并不重要。

泛化：XSAM

第三项工作

XSAM

ICLR 2026

通讯作者（指导学生完成）

SAM：经典的基于优化的泛化增强方法

原始目标

$$\min_{\theta} \max_{\|\epsilon\|_2 \le \rho} \mathcal{L}(\theta + \epsilon)$$

θ 为模型参数，$\mathcal{L}$ 为训练损失，ρ 为扰动半径。

- 通过最小化参数邻域内的最大损失；
- 从而寻找具有更平坦的损失景观。

近似实现

$$\epsilon^*(\theta) \approx \rho \frac{\nabla_\theta \mathcal{L}(\theta)}{\|\nabla_\theta \mathcal{L}(\theta)\|_2}$$

$$\theta_{t+1} = \theta_t - \eta_t \nabla_\theta \mathcal{L}\left(\theta_t + \rho \frac{\nabla_\theta \mathcal{L}(\theta_t)}{\|\nabla_\theta \mathcal{L}(\theta_t)\|_2}\right).$$

- 沿梯度方向施加扰动，近似最大值点；
- 再用扰动点的梯度更新参数。

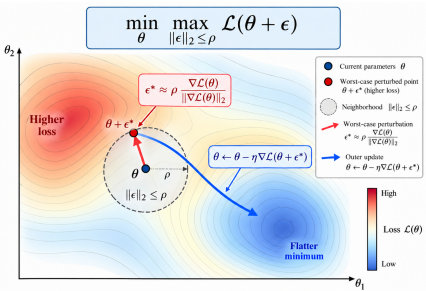
为什么可以用扰动点的梯度更新当前参数？

核心问题：梯度的求解位置和作用位置存在偏移

现有的工作机制解释

- 近似丢掉了最大值点关于当前参数的梯度；
- 近似等价于在原始损失上增加梯度范数惩罚；
- 这么做能抑制 Hessian 最大特征值；
- . . .

更直观的工作机制解释



SAM minimizes the worst-case loss in a local neighborhood to seek flatter minima.

扰动点的梯度，相对于当前参数点的梯度，能更好地近似局部最大值点所在方向。

Proposition 1. Let $L : \mathbb{R}^n \to \mathbb{R}$ be twice continuously differentiable and admit a second-order approximation at ϑ_0, with

- $\nabla L(\vartheta_0) = g_0 \neq 0$;
- $\nabla L\left(\vartheta_0 + \rho \frac{g_0}{\|g_0\|}\right) = g_1$, which is not parallel to g_0;
- Hessian $H = \nabla^2 L(\vartheta_0)$ positive definite.

Then there exists $\rho_0 > 0$ such that for all $\rho_m > \rho_0$:

$$L\left(\vartheta_0 + \rho_m \frac{g_1}{\|g_1\|}\right) > L\left(\vartheta_0 + \rho_m \frac{g_0}{\|g_0\|}\right).$$

SAM better approximates the direction toward the maximum in the vicinity than SGD.

扰动半径内，扰动点方向的损失值会相对更大。

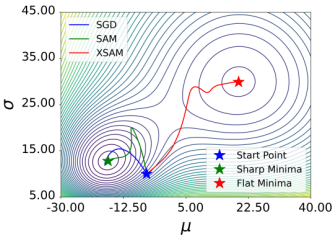
更直接的做法：XSAM

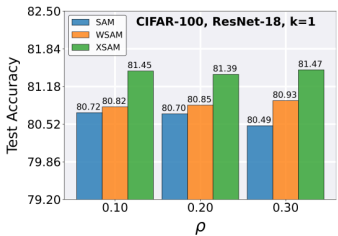
- SAM 的工作原理：近似邻域内最大值所在方向。
- 本质上，要最小化参数邻域内的最大损失。
- 最直接的做法：近似最大值所在方向，然后反向远离。
- 准确找邻域内最大值，代价不可承受。
- 在最大值点最有可能出现的二维平面、指定半径上找。
- 二维平面 + 指定半径：代价可以降到可以忽略。

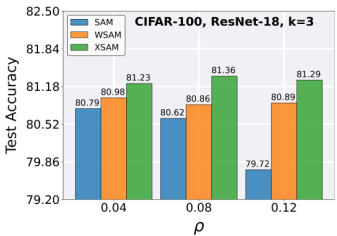
$$
\begin{aligned}
g_0 &= \nabla \mathcal{L}(\theta_t), \\
g_1 &= \nabla \mathcal{L}\left(\theta_t + \rho \frac{g_0}{\|g_0\|_2}\right), \\
v_0 &= \frac{g_0}{\|g_0\|_2}, \qquad v_1 = \frac{g_1}{\|g_1\|_2}, \\
\psi &= \arccos(v_0^\top v_1), \\
v(\alpha) &= \frac{\sin((1-\alpha)\psi)}{\sin\psi} v_0 + \frac{\sin(\alpha\psi)}{\sin\psi} v_1, \\
\alpha^* &= \arg\max_{\alpha \in [0,a]} \mathcal{L}(\theta_t + \rho_m v(\alpha)), \\
\theta_{t+1} &= \theta_t - \eta_t \|g_1\|_2 v(\alpha^*).
\end{aligned}
$$

实验结果：泛化性能更好

Dataset	CIFAR-10			CIFAR-100			Tiny-ImageNet		
Model	VGG-11	ResNet-18	DenseNet-121	VGG-11	ResNet-18	DenseNet-121	VGG-11	ResNet-18	DenseNet-121
SGD	93.19±0.11	96.15±0.05	96.34±0.11	71.46±0.17	78.55±0.20	81.78±0.06	47.44±0.33	57.02±0.42	61.93±0.10
SAM	93.83±0.06	96.59±0.06	96.97±0.02	74.01±0.05	80.93±0.11	83.81±0.02	51.96±0.26	62.81±0.09	66.31±0.09
XSAM	**94.25**±0.14	**96.74**±0.04	**97.15**±0.03	**74.21**±0.14	**81.24**±0.07	**83.96**±0.10	**52.58**±0.38	**63.82**±0.23	**66.81**±0.08







更多内容：单步与多步扰动

- **多步 SAM 为什么性能趋于退化**：多步扰动后，扰动点的梯度不一定能比当前参数点更好地近似局部最大值点方向。
- XSAM 无论单步还是多步扰动，都是锁定最大值点最有可能出现的二维平面。
- 多步扰动能更好锁定；原作者据此概括：XSAM 多步扰动性能不会下降。

$$v_0 = \frac{\vartheta_k - \vartheta_0}{\|\vartheta_k - \vartheta_0\|_2}, \qquad v_1 = \frac{g_k}{\|g_k\|_2}.$$

当前已知的最大值所在的平面

神经网络架构：ResFlow

第四项工作

ResFlow

KDD 2024

通讯作者（和虾皮的搜推团队合作完成）

搜索与推荐

- 要求具有实时性：如 $1\,\mathrm{s}$ 内返回搜索排序或推荐列表。
- 要求具有准确性：搜索内容、推荐内容要符合用户需求。

提升准确性的方法之一：多任务学习

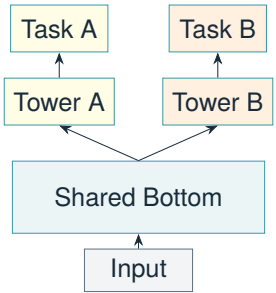
购物场景

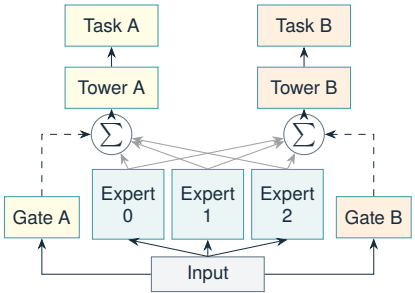
- 点击率预估
- 加购物车概率预估
- 购买率预估

数字内容场景（短视频）

- 点击概率预估
- 喜欢概率预估
- 转发概率预估
- 评论概率预估

现有多任务学习方法：共享底层网络



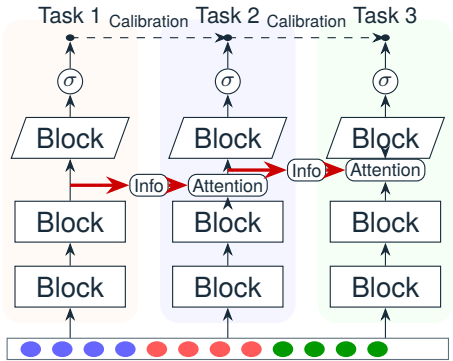


性能一般，准确率提升有限

现有多任务学习方法：专用信息迁移网络

方法二

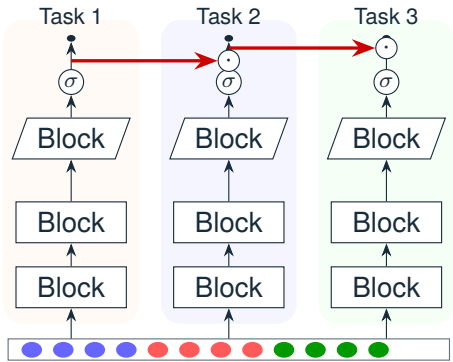
- 专用信息迁移网络
- 代价高
- 实时性不满足



现有多任务学习方法：仅迁移最后的概率输出

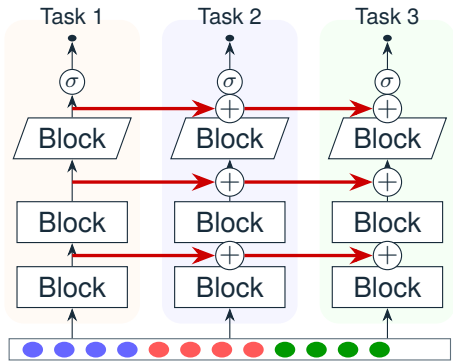
方法三

- 仅迁移最后的概率输出
- 信息传递不足



ResFlow：残差流动

- 通过残差连接迁移各层输出。
- 后续任务只需要学习上一个任务的残差。
- 广泛实践证明：残差容易学，泛化性能更好。
- 只有一个加法：代价极低，满足实时性要求。



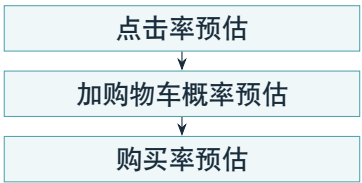
实验结果

Dataset	NSE	PLE	AITM	ESMM	ESCM^2-IPW	ESCM^2-DR	DCMT	ResFlow (ours)
S0	0.619 ± 0.001	0.630 ± 0.005	0.636 ± 0.002	0.632 ± 0.001	0.624 ± 0.007	0.622 ± 0.006	0.640 ± 0.001	$\mathbf{0.656 \pm 0.001}$
S1	0.621 ± 0.002	0.624 ± 0.003	0.623 ± 0.001	0.623 ± 0.003	0.624 ± 0.002	0.623 ± 0.003	0.632 ± 0.002	$\mathbf{0.647 \pm 0.002}$
S0&S1	0.623 ± 0.002	0.635 ± 0.001	0.637 ± 0.001	0.637 ± 0.003	0.623 ± 0.005	0.623 ± 0.001	0.634 ± 0.002	$\mathbf{0.661 \pm 0.001}$
AliCCP	0.624 ± 0.002	0.640 ± 0.002	0.644 ± 0.001	0.641 ± 0.003	0.625 ± 0.005	0.627 ± 0.003	0.643 ± 0.002	$\mathbf{0.664 \pm 0.002}$
AE-ES	0.861 ± 0.002	0.873 ± 0.002	0.876 ± 0.001	0.867 ± 0.003	0.868 ± 0.003	0.871 ± 0.002	0.886 ± 0.003	$\mathbf{0.893 \pm 0.001}$
AE-FR	0.842 ± 0.002	0.852 ± 0.002	0.856 ± 0.002	0.851 ± 0.001	0.873 ± 0.007	0.870 ± 0.005	0.874 ± 0.003	$\mathbf{0.885 \pm 0.001}$
AE-NL	0.831 ± 0.003	0.844 ± 0.002	0.843 ± 0.001	0.840 ± 0.002	0.854 ± 0.006	0.854 ± 0.004	0.858 ± 0.001	$\mathbf{0.864 \pm 0.001}$
AE-US	0.826 ± 0.001	0.851 ± 0.003	0.843 ± 0.002	0.827 ± 0.002	0.843 ± 0.006	0.841 ± 0.003	0.863 ± 0.003	$\mathbf{0.872 \pm 0.001}$
AE-RU	0.870 ± 0.003	0.886 ± 0.001	0.882 ± 0.002	0.878 ± 0.002	0.882 ± 0.006	0.880 ± 0.006	0.887 ± 0.001	$\mathbf{0.913 \pm 0.002}$
Shopee-2	0.865 ± 0.001	0.860 ± 0.003	0.855 ± 0.006	0.882 ± 0.001	0.840 ± 0.012	0.812 ± 0.041	0.867 ± 0.001	$\mathbf{0.902 \pm 0.001}$
Shopee-3	0.877 ± 0.002	0.877 ± 0.003	0.871 ± 0.003	0.893 ± 0.001	/	/	/	$\mathbf{0.910 \pm 0.002}$

预测准确率比现有各类方法都更高

场景拓展

购物场景



操作具有顺序依赖
（按顺序排列）

数字内容场景（短视频）

- 点击概率预估
- 喜欢概率预估
- 转发概率预估
- 评论概率预估

操作不具有顺序依赖
（按数据稀疏性排列）

任务拓展

- 概率预测：如点击率预测
- 回归任务：如评分预测

把回归问题看作一个多任务问题

- 任务 1：评分大于等于 1 的可能性
- 任务 2：评分大于等于 2 的可能性
- 任务 3：评分大于等于 3 的可能性
- 任务 4：评分大于等于 4 的可能性
- 任务 5：评分大于等于 5 的可能性

在线部署

相较于之前部署的方法

OPU	$\uparrow 1.29\%$
Online CTR	$\uparrow 0.25\%$
Online CTCVR	$\uparrow 1.37\%$

第五项工作

表示学习：CRED

投稿中，指导学生完成

其他表示学习相关工作：WWW 2023，TORS 2025

基于数据增强的自监督表示学习

- 不变性：
  - 增强后的数据的表示，和原数据的表示，尽可能保持一致
  - **能完成聚类**
- 等变性：
  - 相同数据增强，无论作用在什么数据上，在表示空间中带来相同的变化
  - **能使表示空间结构化**

结构化的更进一步目标：解耦的表示

- 解耦表示：不同的变化在不同的表示空间中体现，彼此不干扰
- 现有方法，其实连等变性都学不好
- **CRED 的目标：基于等变性的解耦表示**

大体思路：等变性不受干扰地被约束在彼此独立的表示空间中 $\Longrightarrow$ 解耦

“不受干扰地”

- 现有方法同时优化不变性和等变性 $\Longrightarrow$ 彼此干扰
- 解决方案：**两阶段方法**
  - 第一阶段，优化不变性，从而形成聚类、簇状结构
  - 第二阶段，各簇内学习等变性，不再需要不变性

簇依赖的旋转等变

- 旋转等变（球面表示空间，合理的变换几乎都是旋转）：

$$\mathcal{L}_{\text{equi}} = \frac{1}{N}\sum_{i=1}^{N} \| f(T(x_i)) - R_{c_i}(\boldsymbol{\theta}_i) f(x_i) \|_2^2$$

- 簇依赖：

$$R_c(\boldsymbol{\theta}) = H_c^{\mathsf{T}} \operatorname{diag}\big(R(\theta_1), \ldots, R(\theta_m), I_{d-2m}\big) H_c$$

H_c 是将簇中心方向对齐到参考轴的 Householder 变换。

“在彼此独立的表示空间中”

$SO(2)$ 子空间：

$$R_c(\boldsymbol{\theta}) = H_c^{\mathsf{T}} \operatorname{diag}\big(R(\theta_1), \ldots, R(\theta_m), I_{d-2m}\big) H_c$$

- 把旋转分解并**限定在若干个彼此垂直的二维子空间**

实验结果：合成数据集

合成数据集上，达到近似完美解耦。

Table 1: DCI evaluation using Random Forest regression on four datasets, with results reported as (D/C/I) triples corresponding to Disentanglement, Completeness, and Informativeness.

Method/Dataset	MPI3D (D/C/I)	Shape3D (D/C/I)	3DIdent (D/C/I)	3DIEBench (D/C/I)
Self-Supervised Invariance				
SimCLR (Chen et al., 2020a)	0.085 / 0.086 / 0.876	0.074 / 0.071 / 0.885	0.129 / 0.096 / 0.926	0.102 / 0.095 / 0.904
Self-Supervised Equivariance				
EquiMOD (Devillers & Lefort, 2022)	0.143 / 0.127 / 0.959	0.125 / 0.118 / 0.968	0.067 / 0.024 / 0.933	0.091 / 0.088 / 0.911
CARE (Gupta et al., 2023)	0.084 / 0.085 / 0.891	0.078 / 0.077 / 0.925	0.147 / 0.119 / 0.928	0.116 / 0.106 / 0.942
Self-Supervised Disentanglement				
IP-IRM (Wang et al., 2021)	0.220 / 0.199 / 0.955	0.135 / 0.110 / 0.952	0.147 / 0.094 / 0.933	0.109 / 0.107 / 0.929
Eastwood et al. (2023)	0.950 / 0.826 / **1.000**	0.937 / 0.766 / **1.000**	0.943 / 0.772 / 0.996	0.362 / 0.297 / 0.952
CRED (raw features)	0.628 / 0.505 / **1.000**	0.630 / 0.494 / **1.000**	**0.989** / 0.940 / **1.000**	0.595 / 0.481 / **1.000**
(RAs only)	0.789 / 0.857 / **1.000**	0.745 / 0.834 / **1.000**	**0.989** / 0.940 / **1.000**	0.745 / 0.829 / **1.000**
(RAs + CI)	**1.000** / **1.000** / **1.000**	**1.000** / **1.000** / **1.000**	0.987 / **0.987** / **1.000**	**0.996** / **0.996** / **1.000**

实验结果：真实数据集

真实数据集上，等变和解耦指标显著提升。

Table 2: Comparison on MNIST, CIFAR-10, and CIFAR-100. Linear probing and clustering accuracies are reported as train/test (top-1 in %). Arrows in the header indicate the preferred direction of each metric.

		Accuracy		Equivariance		Disentanglement	
	Method	Linear Eval. (Train / Test)↑	Clustering Acc. (Train / Test)↑	Rot. Equi. $\rho_f \downarrow$	Rel. Equi. $\gamma_f \downarrow$	Mean Overlap↓	Mean Domination↑
MNIST	SimCLR (Chen et al., 2020a)	99.82 / 99.70	98.90 / 96.71	0.5564	9.9667	0.9080	0.1791
	CARE (Gupta et al., 2023)	99.87 / 99.66	97.17 / 90.01	0.4605	0.5159	0.8389	0.2108
	EquiMOD (Devillers & Lefort, 2022)	**99.88** / 99.65	97.41 / 97.17	0.6458	5.6121	0.8937	0.1860
	Eastwood et al. (2023)	99.82 / **99.78**	93.22 / 91.58	0.3282	0.0361	0.3844	0.4053
	IP-IRM (Wang et al., 2021)	99.65 / 99.75	45.61 / 47.18	0.6563	0.3957	0.8157	0.2209
	CRED	99.65 / 99.72	**99.25** / **99.49**	**0.0148**	**0.0116**	**0.0430**	**0.9420**
CIFAR-10	SimCLR (Chen et al., 2020a)	**92.68** / 92.03	87.57 / 83.19	0.9301	2.6598	0.9190	0.5405
	CARE (Gupta et al., 2023)	92.12 / 92.09	86.09 / 84.32	0.8962	1.0413	0.9112	0.5444
	EquiMOD (Devillers & Lefort, 2022)	92.48 / **92.24**	84.62 / 80.65	0.3623	0.1643	0.7721	0.6139
	Eastwood et al. (2023)	92.65 / 92.18	84.43 / 83.32	0.3184	0.1030	0.1657	0.9072
	IP-IRM (Wang et al., 2021)	92.62 / 92.04	40.75 / 42.94	0.9695	2.3808	0.9149	0.5425
	CRED	92.07 / 92.06	**88.60** / **86.81**	**0.0220**	**0.0894**	**0.1356**	**0.9322**
CIFAR-100	SimCLR (Chen et al., 2020a)	83.65 / 72.05	49.74 / **45.81**	0.9829	8.3676	0.8769	0.5615
	CARE (Gupta et al., 2023)	83.37 / 71.84	48.67 / 45.72	0.9729	3.6219	0.8797	0.5601
	EquiMOD (Devillers & Lefort, 2022)	**84.96** / **72.41**	48.22 / 43.80	0.9684	2.6871	0.9244	0.5378
	Eastwood et al. (2023)	74.94 / 72.19	38.54 / 36.08	0.2223	0.1814	0.1359	0.9321
	IP-IRM (Wang et al., 2021)	83.41 / 72.17	48.01 / 45.24	0.9692	6.2067	0.8950	0.5525
	CRED	82.55 / 71.96	**50.55** / 42.49	**0.0759**	**0.0904**	**0.1203**	**0.9398**

理论结果

- 给定条件下，对于彼此垂直的数据增强，可以实现完美解耦
- 一些条件下，彼此耦合的数据增强，也可以实现完美解耦
- 不仅可以解耦，还可以实现表示和潜在因子之间的单调映射

空中楼阁

其实整个基于数据增强的自监督表示学习领域都是空中楼阁

地基有问题：现有数据增强无法很好满足理论需求，
哪怕是不变性，实际上都很难学好。

第六项工作

早期在其他领域的研究

计算机图形学：Sparse SVBRDF

TOG 2016，第一作者

SVBRDF

- 表面材质建模
  - 即，通过光线数据和物体在光下的照片数据，求解材质的光照反射属性
- 光射属性，本质上是高维的、复杂的
  - 可以用类似频域分解的方式近似拟合
  - 但可用频谱非常广
  - **直接拟合需要拍大量照片**

基于稀疏性假设，降低所需照片数量

- 前人方法：约束核范数
  - 核范数：矩阵所有奇异值之和，$\|M\|_* = \sum_j \sigma_j(M)$
  - 只是一个近似的稀疏性惩罚
  - 依旧需要大量照片

直接的、极致的稀疏性惩罚

核心思路：

基材可以是频谱的任意组合（以保证建模的准确性），对应于矩阵的秩

- 全局建模用到的基材的数量尽可能少　低秩
- 每个点也用尽可能少的基材去拟合
  每个点用到尽可能少的秩

实验结果

照片需求量从几千降到几十甚至一



Figure 1: SVBRDFs reconstructed by our method and relit. The Bear model (a) is recovered from a single image ($k = 1$), while Mouse (b), Pig (c), and PaintSph (d) are reconstructed from multiple images ($k = 36$, 54, and 17, respectively). The sparse blend solved for at each surface point combines a single representative ($n = 1$) in the Bear, three ($n = 3$) in the Mouse, four ($n = 4$) in the Pig, and five ($n = 5$) in the PaintSph.

个人履历

2010–2014 本科，上海交通大学，ACM 班

2014–2020 博士，上海交通大学，计算机科学与技术

导师：俞勇教授

2020–2026 助理教授，上海财经大学

信息管理与工程学院（2020–2024）

计算机与人工智能学院（2024–2026）

感谢聆听！